01 CONTEXTO

Contexto do Desafio

Você é cientista de dados na WeCogno e está atuando em um projeto para um dos maiores bancos do país, que oferece empréstimos para clientes pessoa física.

O banco busca **reduzir seus índices de inadimplência** e contratou sua equipe para apoiar na construção de uma solução baseada em dados que auxilie na tomada de decisão durante o processo de concessão de crédito.

Seu papel neste projeto é desenvolver um modelo preditivo capaz de estimar, em tempo real, a probabilidade de inadimplência de contratos de crédito solicitados por clientes.

Além da construção do modelo, o banco também espera que você proponha políticas de crédito que indiquem como utilizar as previsões geradas para orientar decisões, como aprovar, rejeitar ou ajustar condições de contratos.

Esse ponto é fundamental, pois o banco ainda não possui uma estratégia definida para aplicação do modelo.

02 OBJETIVO DO CASE

Objetivo do Case

O objetivo deste case é que você desenvolva uma solução completa para o banco, composta por:

- Um **modelo preditivo** que estime a probabilidade de inadimplência de contratos de crédito solicitados por clientes.
- Uma **política de crédito sugerida** com base nas previsões geradas, indicando como o banco pode utilizar a saída do modelo para tomar decisões.

As previsões devem ser aplicadas aos contratos presentes na base `base_submissao.parquet`, que representa um conjunto de solicitações recentes para as quais o banco deseja tomar decisões mais assertivas.

Para isso, você terá à disposição:

- O histórico de empréstimos anteriores dos clientes desde 2017.
- Informações sobre os pagamentos das parcelas desses contratos.
- Dados cadastrais dos clientes.

O banco deixou a cargo do time de dados a decisão sobre qual definição de inadimplência utilizar como referência. Ou seja, você tem **liberdade para explorar** diferentes formas de definir o que é inadimplência, construir sua própria variável target e justificar a escolha feita.

03 BASES DE DADOS

Bases de dados disponíveis

Você terá acesso a quatro bases de dados com informações históricas sobre clientes, contratos de crédito e pagamentos. Essas bases foram extraídas dos sistemas internos do banco e seguem o padrão atualmente utilizado pelas áreas de crédito e risco.

As tabelas se relacionam principalmente por duas chaves:

CHAVE	DEFINIÇÃO
id_cliente	Identifica cada cliente de forma única
id_contrato	Identifica cada contrato de crédito realizado

A estrutura de cada base é:

base_cadastral.parquet
Reúne dados cadastrais dos clientes, como sexo, estado civil, renda, ocupação, entre outros atributos demográficos e socioeconômicos. Cada linha representa um cliente único (id_cliente).

base_submissao.parquet
Contém os contratos de crédito que estão em análise no momento, e para os quais o modelo deverá gerar previsões de inadimplência. Cada linha representa o contrato mais recente de um cliente, identificado por id_cliente.

historico_emprestimos.parquet

Apresenta o histórico de contratos anteriores realizados por cada cliente. Contém informações como valores contratados, status final, tipo de produto, datas e demais dados relevantes. Cada linha representa um contrato específico (id_contrato) vinculado a um cliente (id_cliente). Um cliente pode ter múltiplos contratos.

historico_parcelas.parquet

Detalha os pagamentos realizados para cada contrato, incluindo valores previstos, valores pagos e datas correspondentes. Cada linha representa uma parcela paga de um contrato, vinculada tanto ao id_contrato quanto ao id_cliente.

Além dessas bases, você receberá um arquivo **dicionario_dados.xlsx** com a descrição completa de todas as variáveis disponíveis.

É sua responsabilidade explorar as relações entre essas tabelas, validar a integridade dos dados e construir uma base de modelagem adequada para o desenvolvimento da solução.